IN1140: Introduksjon til språkteknologi

Forelesning #10

Lilja Øvrelid

Universitetet i Oslo

19 oktober 2020

Semantikk

Forrige uke:

- Semantikk
- Studiet av betydning slik det uttrykkes gjennom språk
- Betydning til morfemer, ord, fraser og setninger
  - leksikal semantikk
  - setningssemantikk
  - (pragmatikk: hvordan konteksten påvirker betydning)

Lingvistiske nivåer

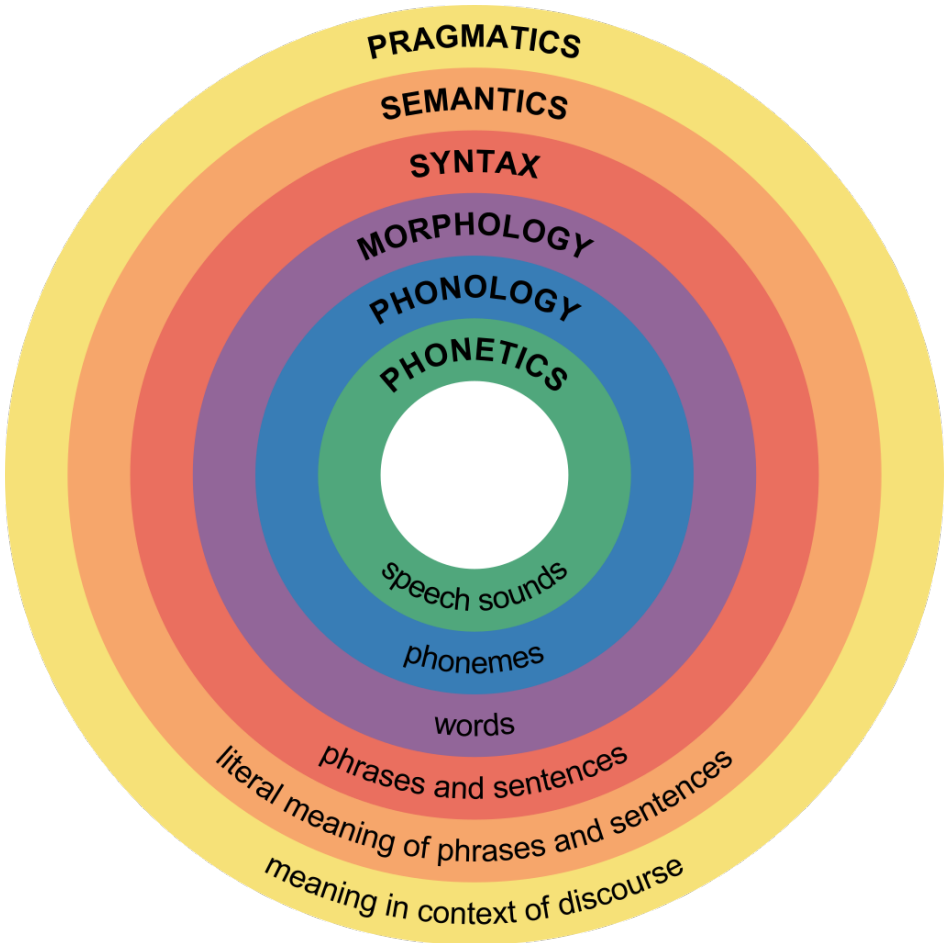

Semantikk i språkteknologi

Tema for i dag:

- Hva slags språkteknologiske oppgaver inngår i semantisk analyse?
- Med hva slags metoder kan disse oppgavene løses?
- Tre nivåer av betydning:
  1. Ord: Word Sense Disambiguation (WSD)
  2. Fraser: Named Entity Recognition (NER)
  3. Setninger: Semantic Role Labeling (SRL)

Ordbetydning ("word sense")

Flertydighet

- *The astronomer married the star* – the star
- *You are free to execute your laws, and your citizens, as you see fit* (Star Trek, Next Generation) – execute
- *Oh, flowers are common here, Miss Fairfax, as people are in London* (Oscar Wilde, The Importance of Being Earnest) – common

Betydningsdisambiguering

- Word Sense Disambigzation (WSD) – akivt felt innenfor språkteknologi
  - gitt en setning med et spesifikt målord ("target word") og en liste med betydninger (f.eks. fra WordNet)
  - angi korrekt betydning for målordet i den setningen
- Klassifisering basert på et annotert datasett

Named Entity Recognition (NER)

- Egennavn inneholder viktig semantisk informasjon
  - enkeltord *Erna, Oslo*
  - NP-fraser *Universitetet i Oslo*
- Automatisk **gjenkjenning** og **kategorisering** av egennavn
- Vanlige kategorier: person, organisasjon, sted (lokasjon), geo-politisk entitet

	ORG						GPE_LOC	
Den	internasjonale	domstolen	har	sete	i	Haag	.	
The	*International*	*Court of Justice*	*has*	*its seat*	*in*	*The Hague*	*.*	

Named Entity Recognition (NER)

- Kategorier

NE Type	**Eksempler**
ORGANIZATION	Omnicom, WHO
PERSON	George Washington, President Obama
LOCATION	Downing St., Mississippi River, Norway
DATE	June, 2011-05-03, 03/05/2011
TIME	two fifty a.m., 1:30 p.m.
MONEY	175 million Canadian Dollars, GBP 10.40
FACILITY	Washington Monument, Stonehenge
GPE	Washington D.C., Norway

Named Entity Recognition (NER)

Oppslag i en navneliste (feks. “gazetteer”)?

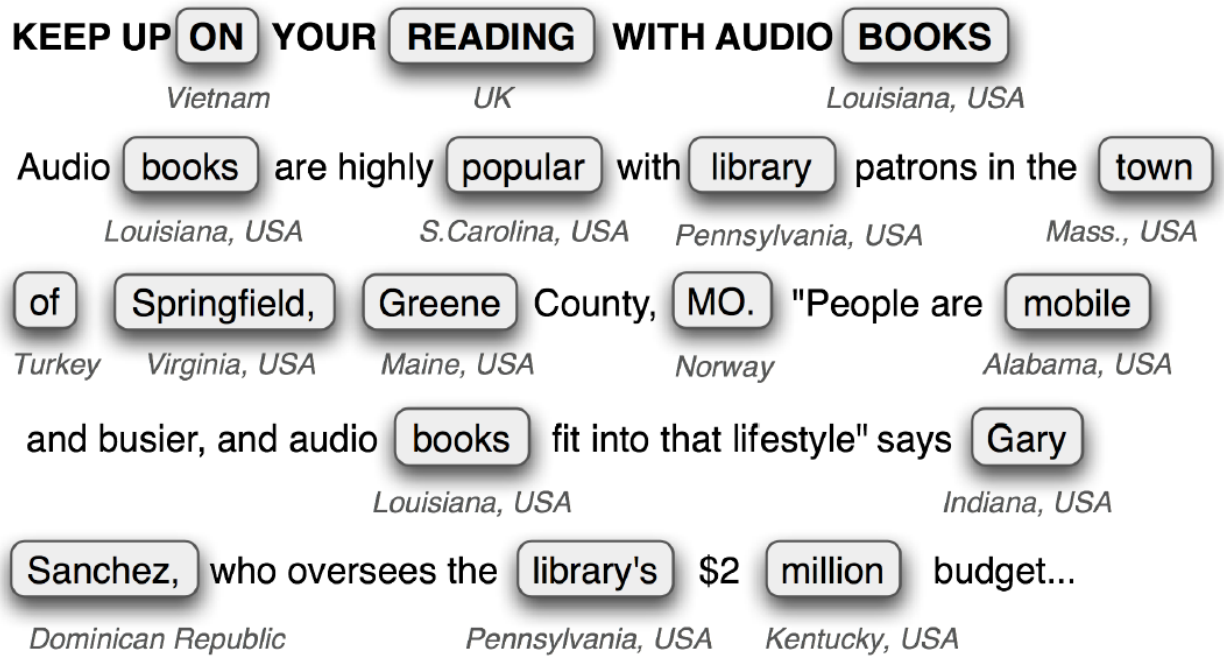

Named Entity Recognition (NER)

Oppslag i en navneliste (feks. "gazetteer")?

- Tar ikke hensyn til kontekst
- Dårlig dekningsgrad, er statisk (må oppdateres)
- En entitet kan strekke seg over flere ord "*Stanford University*"
- Navn kan inneholde andre navn "*Cecil H. Green Library*"

Named Entity Recognition (NER)

Flertydighet

- Samme navn kan referere til forskjellige entiteter av samme type
  - JFK – presidenten og hans sønn
- Samme navn kan referere til entiteter av forskjellig type
  - JFK – flyplass
  - **Metonymi**: et systematisk forhold der vi bruker ett aspekt ved et konsept for å referere til et annet aspekt ved konseptet
    f.eks. bygning-for-organisasjon: *The White House claims that . . .*
- Trenger manuelt annotert korpus

Semantiske roller

- *The dog bit the mailman* er ikke det samme som *The mailman bit the dog*
- Sammenligne med *The dog was bitten by the mailman*
- Semantiske roller beskriver "hvem som gjør hva mot hvem"
  $[\text{The mailman}]_{\text{AGENT}}$ bit $[\text{the dog}]_{\text{PATIENT}}$

Semantic Role Labeling

- Gitt et predikat i en setning, finn dets semantiske roller
- Gir oss en felles representasjon for:
  - $[_{Arg0}$Big Fruit Co.] increased $[_{Arg1}$the price of bananas]
  - $[_{Arg1}$The price of bananas] was increased again by $[_{Arg0}$Big Fruit Co.]
  - $[_{Arg1}$The price of bananas] increased $[_{Arg2}$5%]

  "Big Fruit Co." er alltid *AGENT* og "the price of bananas" er alltid *PATIENT*
- Behov for manuelt annotert korpus

Andre semantiske oppgaver: Entailment

- *Apple bought Cisco*
- *Apple acquired Cisco*
- *Cisco was taken over by Apple*

- Spørsmål: *Who bought Cisco?*
- Forventet svar: *Apple bought Cisco*
  - *Cisco's acquisition by Apple* $\rightarrow$ (entails) Apple bought Cisco

Andre semantiske oppgaver: Negasjon

- *Apple acquired Cisco*
- *Apple did not acquire Cisco*
- *Apple failed to acquire Cisco*
- *Apple denied not acquiring Cisco*

Negasjon – fra forskningsfronten!

- Automatisk negasjonsanalyse – internasjonal forskningskonkurranse
  - *SEM Shared Task on Negation Resolution
  - system som angir
    - negation **cue**
    - negation scope
    - negated *event*
  - There was **no** *answer*.
- Pågående annotasjonsprosjekt ved LTG: norsk negasjon

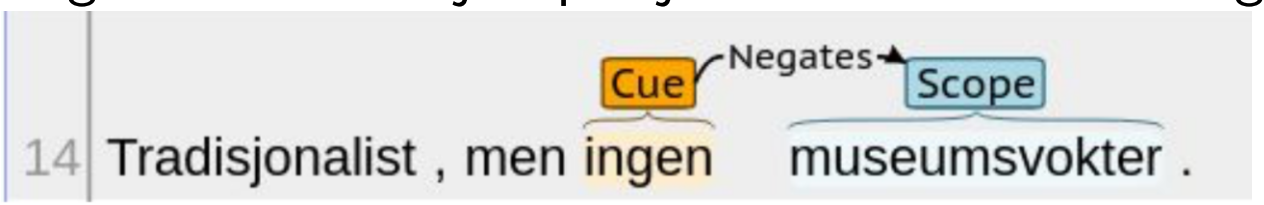

Metoder

Metoder

- Veiledet klassifisering på ulike nivåer
  - Gitt et ord i en setning, og en liste av mulige betydninger, velg en betydning (den mest sannsynlige?). (WSD)
  - For hvert ord i en setning, avgjør om det tilhører en entitet av een viss kategori (NER)
  - Gitt et predikat i en setning, finn dets semantiske roller. (SRL)
- Ikke-veiledet tilegnelse av semantisk informasjon fra rå tekst
  - Distribusjonell semantikk:
  - Ord som forekommer i lignende kontekster har lik betydning
    `http://vectors.nlpl.eu/explore/embeddings/en/similar/`

$\Rightarrow$ **Maskinlæring**

Semantiske ressurser

Semantiske ressurser

- Klassifisering forutsetter treningsdata.
- Leksikalske databaser (WordNet, FrameNet).
- Korpuser annotert med semantisk informasjon (SemCor, CoNLL03/NorNE, PropBank).

WordNet

- Manuelt konstruert database
- Betydningen til ord karakteriseres gjennom **relasjoner** til andre ord
- Semantiske konsepter karakteriseres gjennom relasjoner til andre konsepter
- Hva slags relasjoner kan det være snakk om?

Relasjoner i WordNet

- Mellom ord:
  - Synonymi (samme betydning).
  - Synonymi-relasjonen grupperer ord i synonymimengder, såkalte **synsets**.
- Mellom konsepter (=synsets)
  - Hypernymi (mer generell, mer spesifikk).
  - Varierer noe, men antonymi og meronymi er også spesifisert for noen synsets.

WordNet

- Elektronisk leksikon
  - Online grensesnitt
  - Lastes ned
  - Tilgjengelig på `http://wordnet.princeton.edu/`
  - Også tilgjengelig via NLTK
- Består av tre separate databaser:
  1. Substantiv (117798 lemmaer)
  2. Verb (11529 lemmaer)
  3. Adjektiv og adverb (22479 adjektiver, 4481 adverb)

WordNet eksempel

- verbet *skim*: synonymer, definisjoner og eksempler

Verb

- S: (v) plane, **skim** (travel on the surface of water)
- S: (v) skim over, **skim** (move or pass swiftly and lightly over the surface of)
- S: (v) scan, **skim**, rake, glance over, run down (examine hastily) *"She scanned the newspaper headlines while waiting for the taxi"*
- S: (v) **skim**, skip, skitter (cause to skip over a surface) *"Skip a stone across the pond"*
- S: (v) **skim** (coat (a liquid) with a layer)
- S: (v) **skim**, skim off, cream off, cream (remove from the surface) *"skim cream from the surface of milk"*
- S: (v) **skim**, skim over (read superficially)

WordNet: substantiver

- Synsets er koblet sammen ved
  - Hyponym/hypernym relasjonen (hovedhierarkiet)
  - Meronymi: del-helhet relasjoner
    - Komponent/del (*leg* – *table*, *finger* – *hand*)
    - Medlem av en gruppe *tree* – *forest*, *student* – *class*
    - Materiale et objekt er laget av (*oxygen* – *water*)
- Ord er koblet sammen ved antonymi

WordNet: substantiv eksempel

- S: (n) **cat**, true cat (feline mammal usually having thick soft fur and no ability to roar: domestic cats; wildcats)
  - *direct hyponym* / *full hyponym*
  - *direct hypernym* / ***inherited hypernym*** / *sister term*
    - S: (n) feline, felid (any of various lithe-bodied roundheaded fissiped mammals, many with retractile claws)
      - S: (n) carnivore (a terrestrial or aquatic flesh-eating mammal) *"terrestrial carnivores have four or five clawed digits on each limb"*
        - S: (n) placental, placental mammal, eutherian, eutherian mammal (mammals having a placenta; all mammals except monotremes and marsupials)
          - S: (n) mammal, mammalian (any warm-blooded vertebrate having the skin more or less covered with hair; young are born alive except for the small subclass of monotremes and nourished with milk)
            - S: (n) vertebrate, craniate (animals having a bony or cartilaginous skeleton with a segmented spinal column and a large brain enclosed in a skull or cranium)
              - S: (n) chordate (any animal of the phylum Chordata having a notochord or spinal column)
                - S: (n) animal, animate being, beast, brute, creature, fauna (a living organism characterized by voluntary movement)

WordNet: substantiv eksempel

- S: (n) organism, being (a living thing that has (or can develop) the ability to act or function independently)
  - S: (n) living thing, animate thing (a living (or once living) entity)
    - S: (n) whole, unit (an assemblage of parts that is regarded as a single entity) *"how big is that part compared to the whole?"; "the team is a unit"*
      - S: (n) object, physical object (a tangible and visible entity; an entity that can cast a shadow) *"it was full of rackets, balls and other objects"*

WordNet: substantiv eksempel

- S: (n) physical entity (an entity that has physical existence)
  - S: (n) entity (that which is perceived or known or inferred to have its own distinct existence (living or nonliving))

WordNet: substantiv eksempel

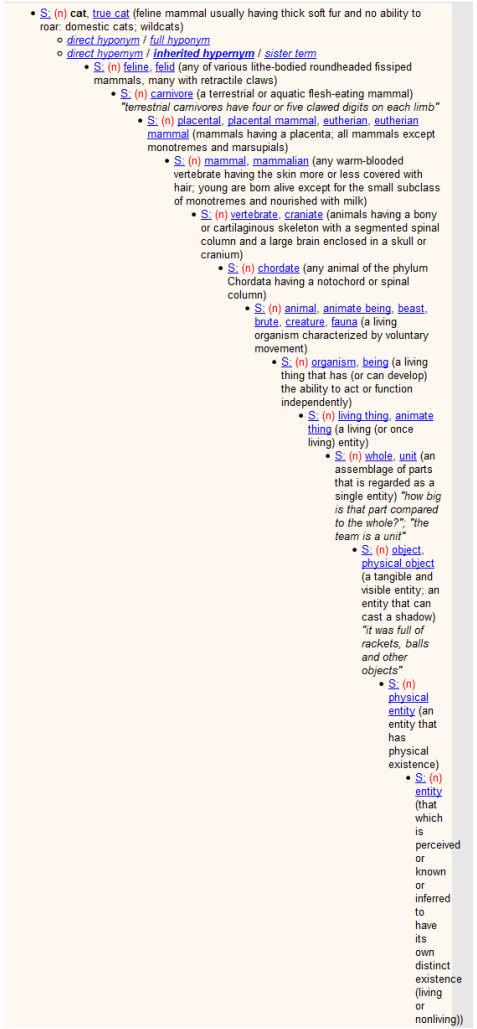

WordNet: substantiv – hyponymi, meronymi, holonymi

Noun

- S: (n) **mammal**, mammalian (any warm-blooded vertebrate having the skin more or less covered with hair; young are born alive except for the small subclass of monotremes and nourished with milk)
  - *direct hyponym* / *full hyponym*
    - S: (n) female mammal (animals that nourish their young with milk)
    - S: (n) tusker (any mammal with prominent tusks (especially an elephant or wild boar))
    - S: (n) prototherian (primitive oviparous mammals found only in Australia and Tasmania and New Guinea)
    - S: (n) metatherian (primitive pouched mammals found mainly in Australia and the Americas)
    - S: (n) placental, placental mammal, eutherian, eutherian mammal (mammals having a placenta; all mammals except monotremes and marsupials)
    - S: (n) fossorial mammal (a burrowing mammal having limbs adapted for digging)
  - *part meronym*
    - S: (n) coat, pelage (growth of hair or wool or fur covering the body of an animal)
    - S: (n) hair, pilus (any of the cylindrical filaments characteristically growing from the epidermis of a mammal) *"there is a hair in my soup"*
  - ***member holonym***
    - S: (n) Mammalia, class Mammalia (warm-blooded vertebrates characterized by mammary glands in the female)

WordNet og polysemi

- Hvor mange betydninger har et ord?
  - Antall synsets ordet forekommer i
- Nærhet i betydning kan utledes fra nærhet i hierarkiet
  - Korteste stien via hyponym/hypernym-linkene mellom synsets

WordNet i språkteknologi

- Utgangspunkt for Word Sense Disambiguation
  - Merke forekomster av et ord med riktig betydning (=synset)
  - Men trenger også korpus der ord er annotert med betydning (SemCor)
- Inforrmasjon brukes også som trekk i mange semantiske NLP-oppgave
- Generalisere over synonymer
- Men: distribusjonell semantikk

NE-annoterte korpuser

- Flere korpuser for engelsk: CoNLL03, ACE, etc.
- Her fokusere på et norsk korpus: NorNE
  - Første fritt tilgjengelige NER-datasett for norsk
  - Samarbeid mellom Schibsted, Språkbanken (Nasjonalbiblioteket) og LTG

NorNE

- Norsk Dependenstrebank (NDT) beriket med semantiske kategorier for egennavn, både Bokmål og Nynorsk
- $\sim$300K tokens for hver, hvorav $\sim$20K er del av et egennavn
- Distributert i såkalt CoNLL-U format med BIO-oppmerking. Forenklet versjon:

1	Den	den	DET	name=B-ORG
2	internasjonale	internasjonal	ADJ	name=I-ORG
3	domstolen	domstol	NOUN	name=I-ORG
4	har	ha	VERB	name=O
5	sete	sete	NOUN	name=O
6	i	i	ADP	name=O
7	Haag	Haag	PROPN	name=B-GPE_LOC
8	.	$.	PUNCT	name=O

NorNE entitetkategorier (Bokmål)

Type	Train	Dev	Test	Total
PER	4033	607	560	5200
ORG	2828	400	283	3511
GPE_LOC	2132	258	257	2647
PROD	671	162	71	904
LOC	613	109	103	825
GPE_ORG	388	55	50	493
DRV	519	77	48	644
EVT	131	9	5	145
MISC	8	0	0	0

https://github.com/ltgoslo/norne/

Semantiske roller

- Aspekt ved setningsbetydning: hvilke roller de forskjellige deltagerene inntar
  - *Nina hevet bilen med jekken*
  - Nina – deltageren som er ansvarlig for å utføre handlingen beskrevet av verbet
  - bilen – blir påvirket av handlingen
  - jekken – middelet som Gina bruker til å utføre handlingen
- Semantiske roller beskriver den semantiske relasjonen som argumenter har til handlingen beskrevet av verbet

Semantiske roller

- eksempelet:

Nina	*hevet*	*bilen*	*med*	*jekken*
AGENT		THEME		INSTRUMENT

Problemer med semantiske roller

- Ikke full enighet rundt rolleinventaret
- Vanskelig å formulere formelle definisjoner av roller
- $\Rightarrow$ generaliserte semantiske roller
  - PROTO-AGENT, PROTO-PATIENT
- $\Rightarrow$ Verbspesifikke roller
- Semantiske ressurser med informasjon om semantiske roller: **PropBank** og FrameNet

PropBank

- Korpus som inneholder alle setningene i Penn Treebank
- Annotert med informasjon om semantiske roller
- Roller er (stort sett) verbspesifikke
  - Arg0, Arg1 = PROTO-AGENT, PROTO-PATIENT
  - Arg2 . . . verbspesifikke

agree.01	
Arg0	Agreer
Arg1	Proposition
Arg2	Other entity agreeing
Ex1	$[_{Arg0}$ *The group*$]$ *agreed* $[_{Arg1}$ *it wouldn't make an offer* $]$
Ex2	$[_{ArgM-TMP}$ *Usually*$]$ $[_{Arg0}$ *John*$]$ *agrees* $[_{Arg2}$ *with Mary*$]$ $[_{Arg1}$ *on everything*$]$

PropBank

- Applikasjon: Semantic Role Labeling
- Gitt et predikat i en setning, finn dets semantiske roller
- Gir oss en felles representasjon for:
  - $[_{Arg0}$Big Fruit Co.] increased $[_{Arg1}$the price of bananas]
  - $[_{Arg1}$The price of bananas] was increased again by $[_{Arg0}$Big Fruit Co.]
  - $[_{Arg1}$The price of bananas] increased $[_{Arg2}$5%]

  "Big Fruit Co." er alltid *AGENT* og "the price of bananas" er alltid *PATIENT*

Semantisk klassifisering

Klassifisering

- Sentral metode innenfor maskinlæring
- Automatisk avgjøre hvilken kategori en observasjon tilhører
- Basert på **treningsdata**: observasjoner der kategorien er kjent
  - e-post $\rightarrow$ {spam, ikke-spam}
  - pasient $\rightarrow$ diagnose
- **Veiledet** klassifisering: klassifisering som benytter manualt annoterte treningsdata

Klassifisering

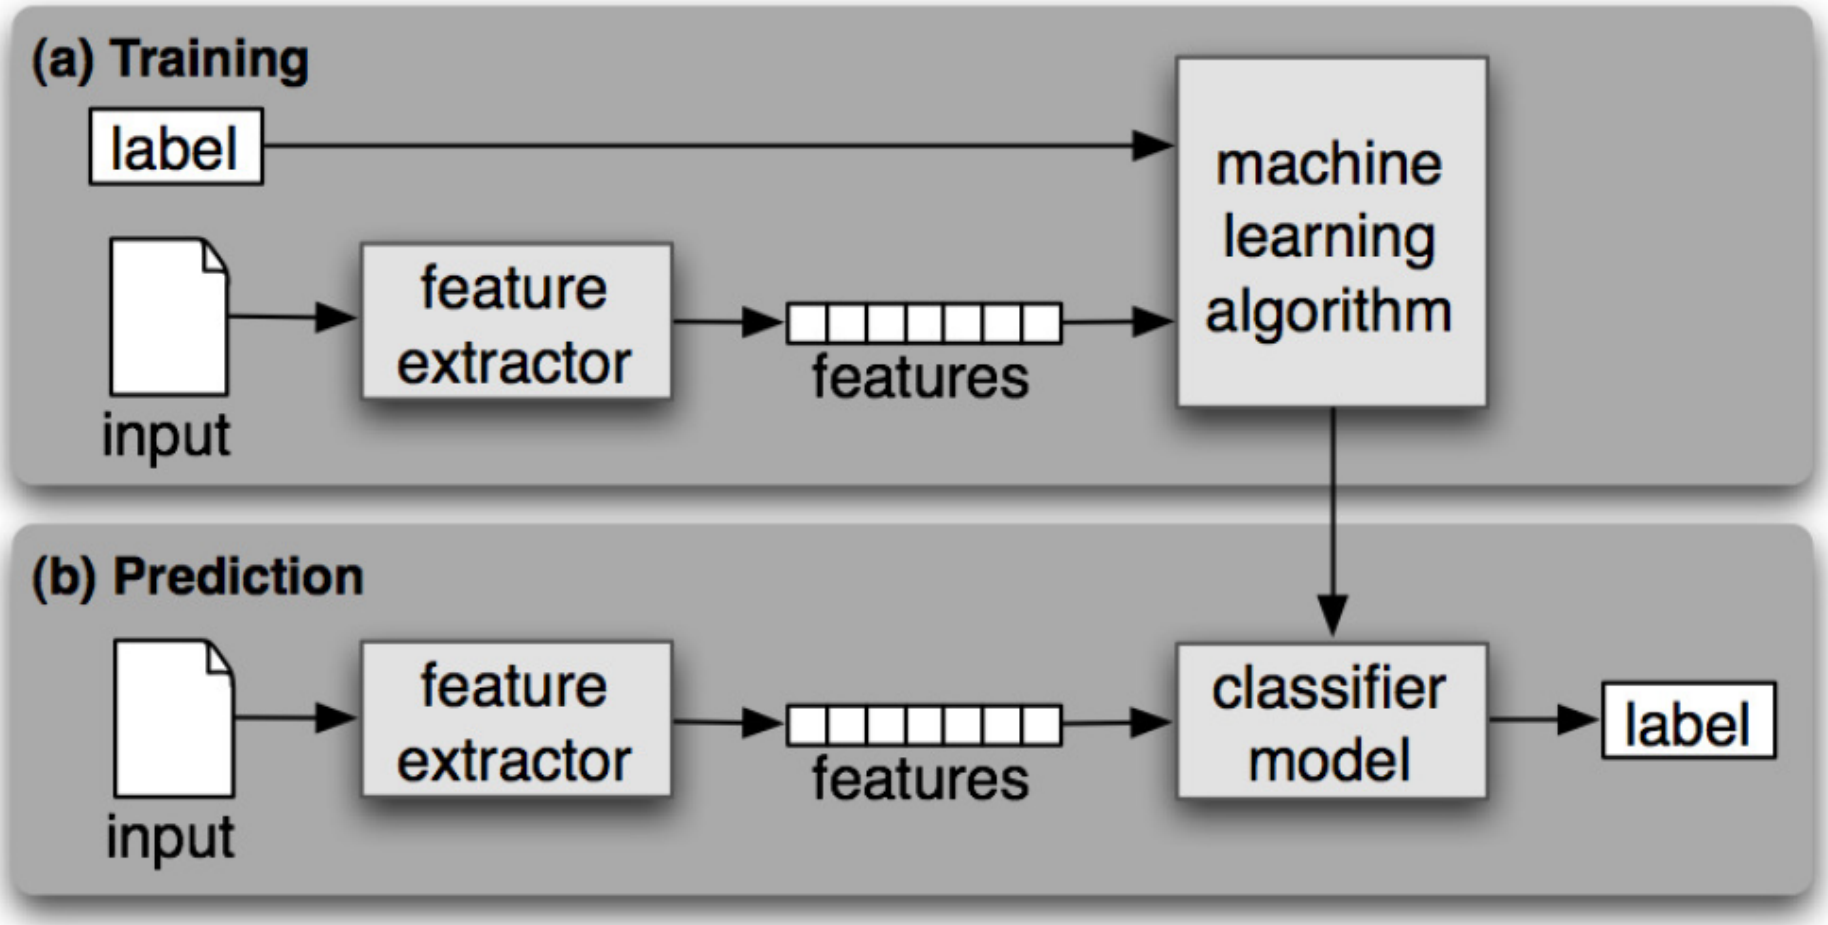

Betydningsdisambiguering

- Første skritt består i å hente ut trekk ("features") fra treningsdataene
- Eksempel: setninger merket med betydning
  - SKIM the pages for a clearer insight: Reading
  - She SKIMS through the novel which seems to fascinate them: Reading
  - Remove the vanilla pod, SKIM the jam, and let it cool: Removing
  - We SKIMMED across the surface of that sodding lake whilst all around us gathered the dark hosts of hell: Self_Motion
- Hvilke trekk ("features") kan vi bruke for å skille mellom de forskjellige betydningene?

Trekk: bag-of-words

- SKIM the pages for a clearer insight: Reading
- She SKIMS through the novel which seems to fascinate them: Reading
- Remove the vanilla pod, SKIM the jam, and let it cool: Removing
- We SKIMMED across the surface of that sodding lake whilst all around us gathered the dark hosts of hell: Self_Motion

Henter ut alle ord (**ikke** ordnet):

- a, clearer, for, insight, pages, the: Reading
- fascinate, novel, seems, she, the, them, through, to, which: Reading
- and, cool, it, jam, let, pod, remove, the, the, vanilla: Removing
- across, all, around, dark, gathered,hell, hosts, lake, of, of, sodding, surface, that, the, the, us, we, whilst Self_Motion

Andre trekk

- Konteksten til målordet kan representeres ved
  - ordformer
  - n-gram
  - lemmaer
  - ordklassetagger
  - kombinasjon av disse
  - $[w_{i-2}, \text{POS}_{i-2}, w_{i-1}, \text{POS}_{i-1}, w_{i+1}, \text{POS}_{i+1}, w_{i+2}, \text{POS}_{i+2}]$
- Remove the vanilla pod, SKIM the jam, and let it cool: Removing
  - **trekkvektor**: [vanilla, JJ, pod, NN, the, DT, jam, NN]

Klassifisering

- Gitt treningsdataene og trekkvektorene, kan en rekke forskjellige maskinlæringsalgoritmer brukes til å trene en klassifiserer
- Her skal vi se på **Naive Bayes**-klassifisering
- Bruker informasjon om ord i konteksten for disambiguering av betydning
- Enkel metode, mye brukt i WSD

Naive Bayes

- Naive Bayes klassifiserer

$$\hat{s} = \underset{s \in S}{\operatorname{argmax}} P(s) \prod_{j=1}^{n} P(f_j|s)$$

- 2 sannsynligheter:
  1. prior-sannsynligheten for betydningen $P(s)$

$$P(s_i) = \frac{count(s_i, w_j)}{count(w_j)}$$

  2. sannsynligheten for individuelle trekk $P(f_j|s)$

$$P(f_j|s) = \frac{count(f_j, s)}{count(s)}$$

Named Entity Recognition (NER)

Vanligste måten å løse denne oppgaven på er ved ord-for-ord klassifisering

- Metoder for sekvensklassifisering, f.eks. Hidden Markov Models (HMM), CRF, LSTM
- BIO-klassifisering: taggen indikerer om ordet befinner seg i begynnelsen (B), innenfor (I) eller utenfor (O) et egennavn, samt indikerer kategori.

BIO-klassifisering

```
honor          O
of             O
George         B_pers
Washington     I_pers
,              O
who            O
...           ...
```

Named Entity Recognition (NER)

American	B_{ORG}
Airlines	I_{ORG}
,	O
a	O
unit	O
of	O
AMR	B_{ORG}
Corp.	I_{ORG}
,	O
immediately	O
matched	O
the	O
move	O
,	O
spokesman	O
Tim	B_{PERS}
Wagner	I_{PERS}
said	O
.	O

Named Entity Recognition (NER)

Data kan representeres ved **trekk** ("features")

- ordform (tokenisering): *of, George, Washington, led*
- lemma: *of, George, Washington, lead*
- shape: lower, capital, capital, lower
- affikser: *of, rge, ton, ead*
- ordklasse: IN, NNP, NNP, VBD
- chunk-kategori: PP, NP, NP, _
- navneliste: 0, 1, 1, 0

(Eller nevrale nettverk som lærer beste representasjon av dataene)

Named Entity Recognition (NER)

- NER-systemer ofte kombinasjon av
  - Lister ("gazetteers")
  - Regler (regel-baserte systemer)
  - Veiledet ("supervised") klassifisering
- Beste systemer for engelsk: 93.5% totalt
- Ulike resultater for ulike klasser

NorNE: resultater for norsk

- Jørgensen, Aasmoe, Husevåg, Øvrelid & Velldal (2020). *NorNE: Annotating Named Entities for Norwegian*
- Nevrale modell for sekvensklassifisering (LSTM-CRF)

	IOB	IOBE	IOBS	IOBES
NorNE-full	90.75	90.45	**90.76**	90.58
NorNE-7	91.86	91.80	91.99	**92.29**
NorNE-6	90.95	90.50	**91.85**	91.38

Table:

NorNE: resultater for norsk

- Jørgensen, Aasmoe, Husevåg, Øvrelid & Velldal (2020). *NorNE: Annotating Named Entities for Norwegian*
- Nevrale modell for sekvensklassifisering (LSTM-CRF)

	Development		Heldout	
Training	BM	NN	BM	NN
BM	89.47	*82.34*	**83.89**	*81.59*
NN	*84.01*	86.53	*76.88*	83.89
BM+NN	**90.92**	**88.03**	83.48	**85.32**

Table:

SRL

- Oppgaven: finne semantiske roller for hvert argument i setninger
- Hvorfor?
  - felles semantisk representasjon for setninger
  - forbedrer en rekke NLP-applikasjoner: spørsmål-svar (QA), maskinoversettelse
- Vanlig å utgå fra syntaktisk analyse

function SEMANTICROLELABEL(*words*) **returns** labeled tree

```
parse ← PARSE(words)
for each predicate in parse do
    for each node in parse do
        featurevector ← EXTRACTFEATURES(node, predicate, parse)
        CLASSIFYNODE(node, featurevector, parse)
```

SRL

- Klassifiserer noder (konstituenter) i det syntaktiske treet
- Trekk (eksempler):
  - Ordformen til hodet (Examiner)
  - Ordklassen til hodet (NNP)
  - Predikatets struktur (`V->VBP NP PP`)
  - NER-klassen til konstituenten (ORG)
  - ...

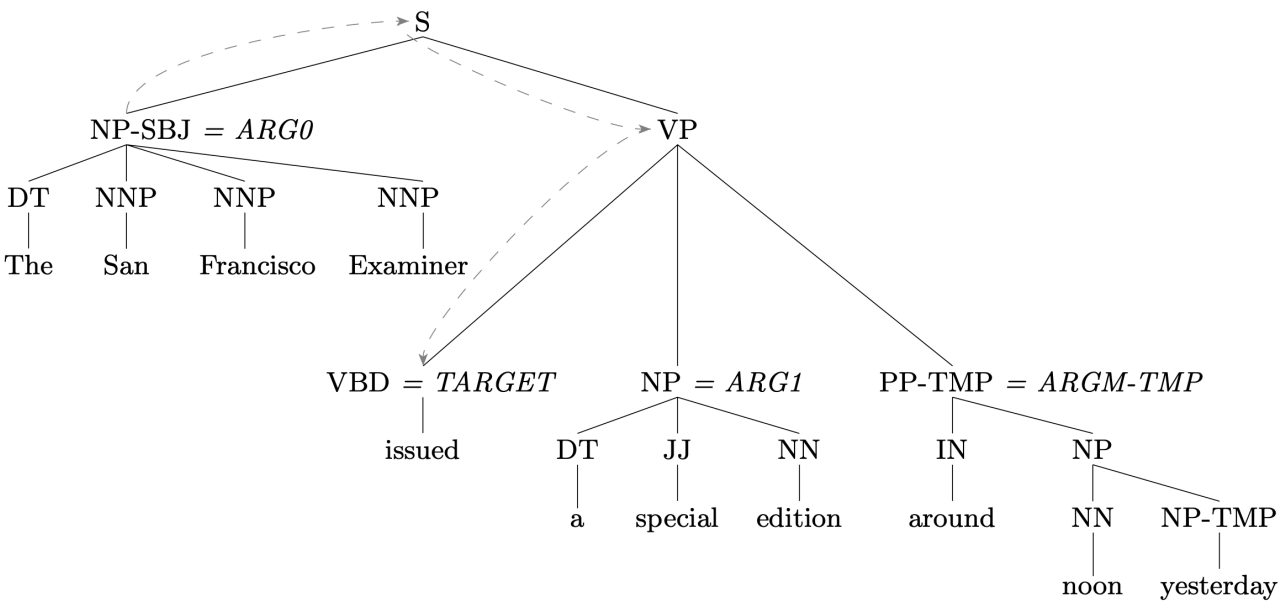

Oppsummering

- Rekke oppgaver inngår i semantisk analyse
  - ordbetydningsdisambiguering (WSD)
  - navnegjenkjenning (NER)
  - semantiske roller (SRL)
  - entailment
  - negasjon
  - ...
- Sentral metode: klassifisering

Oppsummering

- For klassifisering trenger vi treningsdata
- Semantiske ressurser
  - WordNet
    - leksikal database
    - innholdsord: substantiver, verb, adjektiver
    - bygget rundt leksikale relasjoner som synonymi, hyponymi, meronymi, etc.
  - Annoterte korpuser:
    - NorNE
    - PropBank

Oppsummering

- Trekkrepresentasjon av treningsdata
  - ord
  - lemma
  - ordklasse
  - NE-klasse
  - syntaktisk kategori
  - etc.
- Forskjellige typer klassifisering
- Naive Bayes-klassifisering for WSD
  - hvordan vi kan beregne den mest sannsynlige betydningen for et ord:
    $\hat{s} = \underset{s \in S}{\operatorname{argmax}} P(s|\overrightarrow{f})$