IN2090 – Databaser og datamodellering 07 – Datamanipulering

Leif Harald Karlsen leifhka@ifi.uio.no



Komplisert eksempel

1 / 43

Finn kundenavn og productnavn på alle kunder som har bestilt en drikkevare som ikke lenger selges ("discontinued") [230 rader]

```
SELECT DISTINCT c.company_name, p.product_name

FROM products AS p

INNER JOIN order_details AS d ON (p.product_id = d.product_id)

INNER JOIN orders AS o ON (o.order_id = d.order_id)

INNER JOIN customers AS c ON (c.customer_id = o.customer_id)

INNER JOIN categories AS g ON (g.category_id = p.category_id)

WHERE p.discontinued = 1 AND

g.category_name = 'Beverages';
```

2/43

Komplisert eksempel med WITH

Finn kundenavn og productnavn på alle kunder som har bestilt en drikkevare som ikke lenger selges ("discontinued") [230 rader]

Flere eksempler: Kombinere aggregater

Finn antall producter som har en pris større eller lik 100 og alle som har en pris mindre enn 100

```
SELECT
(SELECT count(*) FROM products WHERE unit_price >= 100) AS expensive,
(SELECT count(*) FROM products WHERE unit_price < 100) AS cheap
```

3/43 4/43

Typer SQL-spørringer

Som sagt tidligere, SQL kan gjøre mye mer enn bare uthenting av data. Det første ordet i en spørring sier hva spørringen gjør:

SELECT henter informasjon (svarer på et spørsmål)

CREATE lager noe (f.eks. en ny tabell)

INSERT setter inn rader i en tabell

UPDATE oppdaterer data i en tabell

DELETE sletter rader fra en tabell

DROP sletter en hel ting (f.eks. en hel tabell)

SQLs ulike fuksjoner

De ulike spørringene er egentlig deler av ulike under-språk av SQL. Vi har

- SDL (Storage Definition Language): 3-skjemaarkitekturens fysiske lag
- DDL (Data Definition Language): 3-skjemaarkitekturens konseptuelle lag
- VDL (View Definition Language): 3-skjemaarkitekturens presentasjonslag
- DML (Data Manipulation Language): innlegging, endring og sletting av data
- DQL (Data Query Language): spørrespråk
- DCL (Data Control Language): integritet og sikkerhet

6/43

Lage ting

- ◆ For å lage tabeller, brukere, skjemaer, osv. bruker vi CREATE-kommandoer
- ◆ For å lage et skjema gjør vi

```
CREATE SCHEMA northwind;
```

• SQL-kommandoen for å lage tabeller har formen:

```
CREATE TABLE <tabellnavn> ( <kolonner> );
```

- hvor <tabellnavn> er et tabellnavn (potensielt prefikset med et skjemanavn)
- og <kolonner> er kolonne-deklareringer
- En kolonne-deklarering inneholder
 - et kolonnenavn, og
 - en type,
 - og en liste med skranker (constraints)

CREATE-eksempel

5 / 43

◆ For å lage Student-tabellen kan vi kjøre

```
CREATE TABLE Student (
    SID int,
    StdName text,
    StdBirthdate date
);
```

• Nå vil følgende tomme tabell finnes i databasen:

Students				
SID (int)	StdName	(text)	StdBirthdate	(date)

Skranker: NOT NULL

- ◆ I mange tilfeller ønsker vi å ikke tillate NULL-verdier i en kolonne
- For eksempel dersom verdien er påkrevd for at dataene skal gi mening
 - F.eks. vi vil aldri legge inn en student dersom vi ikke vet navnet på studenten
- eller verdien er nødvendig for at programmene som bruker databasen skal fungere riktig
- ◆ Vi kan da legge til en NOT NULL-skranke til kolonnen
- For eksempel:

```
CREATE TABLE Student (
    SID int,
    StdName text NOT NULL,
    StdBirthdate date
);
```

Skranker: UNIQUE

- Dersom vi ønsker at en kolonne aldri skal gjenta en verdi (altså inneholde duplikater)
- ♦ kan vi bruke UNIQUE-skranken
- For eksempel, student-IDen SID er unik
- Så for at databasen skal håndheve dette kan vi lage tabellen slik:

```
CREATE TABLE Student (
    SID int UNIQUE,
    StdName text NOT NULL,
    StdBirthdate date
);
```

9/43

Skranker: PRIMARY KEY

- ◆ I tillegg til å være unik, så må SID-verdien aldri være ukjent, ettersom det er primærnøkkelen i tabellen
- ◆ Så vi burde derfor ha både UNIQUE og NOT NULL, altså:

```
CREATE TABLE Student (
SID int UNIQUE NOT NULL,
StdName text NOT NULL,
StdBirthdate date
):
```

 Men, det finnes også en egen skranke for dette, nemlig PRIMARY KEY som inneholder UNIQUE NOT NULL. Så,

```
CREATE TABLE Student (
SID int PRIMARY KEY,
StdName text NOT NULL,
StdBirthdate date
);
```

er ekvivalent som over

 Merk, kan kun ha én PRIMARY KEY per tabell, må bruke UNIQUE NOT NULL dersom vi har flere kandidatnøkler

Alternaiv syntaks for skranker

• Man kan også skrive skrankene til slutt, slik:

```
CREATE TABLE Student (
SID int,
StdName text NOT NULL,
StdBirthdate date,
CONSTRAINT sid_pk PRIMARY KEY (SID)
);
```

- Nå har skrankene navn (sid_pk, name_nn)
- Denne syntaksen er nødvendig om vi ønsker å ha skranker over flere kolonner
- F.eks. om kombinasjonen av StdName og StdBirthdate alltid er unik:

```
CREATE TABLE Student (
    SID int,
    StdName text NOT NULL,
    StdBirthdate date,
    CONSTRAINT sid_pk PRIMARY KEY (SID),
    CONSTRAINT name_bd_un UNIQUE (StdName, StdBirthdate)
);
```

Skranker: REFERENCES

- Det er vanlig i relasjonelle databaser at en kolonne refererer til en annen
- Fremmednøkler er eksempler på dette
- I slike tilfeller ønsker vi å begrense de tillatte verdiene i kolonnen til kun de som finnes i den den refererer til
- Dette kan gjøres med REFERENCES-skranken
- F.eks. for å lage TakesCourse-tabellen, kan vi gjøre følgende:

```
CREATE TABLE TakesCourse (
    SID int REFERENCES Student (SID),
    CID int REFERENCES Course (CID),
    Semester text
);
```

◆ Nå vil man kun kunne legge inn SID-verdier som allerede finnes i Students(SID) og kun CID-verdier som allerede er i Courses(CID) Sette inn data

- ◆ For å sette inn data i en tabell bruker vi INSERT-kommandoen
- INSERT brukes på følgende måte:

- Så, for å sette inn radene
 - ♦ (0, 'Anna Consuma', '1978-10-09'), og
 - ♦ (1, 'Peter Young', '2009-03-01')
- inn i Students, kan vi gjøre:

13 / 43

14 / 43

Andre måter å sette inn data

- ◆ Vi kan bruke resultatet fra en SELECT-spørring i stedet for VALUES
- For ekesmpel:

```
CREATE TABLE Students2018 (
    SID int PRIMARY KEY,
    StdName text NOT NULL
);

INSERT INTO Students2018

SELECT S.SID, S.StdName
    FROM Students AS S INNER JOIN TakesCourse AS T
    ON (S.SID = T.SID)

WHERE T.Semester LIKE '%18';
```

Ny tabell basert på SELECT direkte

Vi kan også kombinere de to kommandoene på forige slide slik:

```
CREATE TABLE Students2018 AS

SELECT S.SID, S.StdName

FROM Students AS S INNER JOIN TakesCourse AS T

ON (S.SID = T.SID)

WHERE T.Semester LIKE '%18';
```

- Dette gir samme data, men merk at vi nå ikke har skrankene PRIMARY KEY og NOT NULL
- Disse må da legges til etterpå

Default-verdier

- Vi kan gi en kolonne en standard/default verdi
- Denne blir brukt dersom vi ikke oppgir en verdi for kolonnen
- For ekesmpel:

```
CREATE TABLE personer (
    pid int PRIMARY KEY,
    navn text NOT NULL,
    nationalitet text DEFAULT 'norge'
);

INSERT INTO personer
VALUES (1, 'carl', 'UK');

INSERT INTO personer(pid, navn) --eksplisitte kolonner
VALUES (2, 'kari');

Vil qi
```

personer

pid	navn	nationalitet
1	Carl	UK
2	Kari	norge

17 / 43

Hvor kommer data fra? (1)

Man skriver som oftest ikke INSERT-spørringer direkte

Den vanligste måten å få data inn i en database på er via programmer som eksekverer INSERT-spørringer (Se senere i kurset), f.eks.:

- data generert av simuleringer, analyse, osv.
- data skrevet av brukere via en nettside, brukergrensesnitt, osv.
- data fra sensorer (f.eks. værdata), nettsider (f.eks. aksjedata, klikk), osv.

SERIAL

- For primærnøkler som bare er heltall, så kan vi bruke SERIAL
- Dette gjør at databasen automatisk genererer unike heltall for hver rad
- Så med

```
CREATE TABLE Student (
    SID SERIAL PRIMARY KEY, -- merk ingen type
    StdName text NOT NULL,
    StdBirthdate date
);

INSERT INTO Students(StdName, StdBirthdate) --eksplisitte kolonner
VALUES ('Anna Consuma', '1978-10-09'),
    ('Peter Young', '2009-03-01'),
        ('Anna Consuma', '1978-10-09');
```

vil vi få

brudenrs			
SID	StdName	StdBirthdate	
1	Anna Consuma	1978-10-09	
2	Peter Young	2009-03-01	
3	Anna Consuma	1978-10-09	

Studente

Merk at man må være sikker på at radene nå faktisk representerer unike ting!

Hvor kommer data fra? (2)

- Man kan også lese data direkte fra filer (f.eks. regneark eller CSV)
- ◆ I PostgreSQL har man COPY-kommandoen får å laste inn data fra CSV
- ◆ Følgende laster inn innholdet fra CSVen ~/documents/people.csv (med separator ',' og null-verdi '') inn i tabellen Persons:

```
COPY persons
FROM '~/documents/people.csv' DELIMITER ',' NULL AS '';
```

- Merk, PostgreSQL krever at man er superuser for å lese filer av sikkerhetsgrunner
- Men man kan alltid lese fra Standard Input (stdin), f.eks. ved å eksekvere følgende (i Bash):

```
$ cat persons.csv | psql <flag> -c
    "COPY persons FROM stdin DELIMITER ',' NULL AS ''"
```

(hvor flag er de vanlige flaggene man bruker for innlogging til databasen)

♦ I Postgres finnes det også en egen \copy-kommando i psql

Eksempel: Jentenavn – datainnlasting

- ◆ La oss finne ut hvilket jentenavn som økte mest i popularitet fra 2017 til 2018
- ◆ SSB har mange dataset, bla.: https://www.ssb.no/statbank/table/10501/ (velg alle navn, og årene 2017 og 2018)
- Lager så tabell for denne dataen:

```
CREATE TABLE jentenavn(navn text, y17 int, y18 int);
```

• Og laster så inn dataene (må endre enkoding og bytte alle . . med .)

```
$ cat Persons.csv | psql <flag> -c
    "COPY jentenavn FROM stdin DELIMITER ';' NULL AS '.'"
```

Eksempel: Jentenavn – finne svaret

Kan så finne svaret vårt:

Svaret er altså "Ada"

21/43

Eksempel: Jentenavn – alternativ løsning

```
ALTER TABLE jentenavn
ADD COLUMN diff int;

UPDATE jentenavn
SET diff = y18 - y17

SELECT *
FROM jentenavn
WHERE diff = (SELECT max(diff)
FROM jentenavn)
```

Eksempler på skrankeovertredelser (violations)

Som sagt tidliere, man har ikke lov til å overtre databaseskjemaet, så hvis vi har

```
CREATE TABLE Students (
    SID int PRIMARY KEY,
    StdName text NOT NULL,
    StdBirthdate date

Så vil );

INSERT INTO Students
    VALUES (0, 'Anna Consuma', '1978-10-09', 1);

Gİ ERROR: INSERT has more expressions than target columns

INSERT INTO Students
    VALUES ('zero', 'Anna Consuma', '1978-10-09');

GİT ERROR: invalid input syntax for integer: "zero"

INSERT INTO Students
    VALUES (0, NULL, '1978-10-09');

GİT ERROR: null value in column "stdname"violates not-null constraint
```

23 / 43

Eksempler på skrankeovertredelser

Og gitt:

Vil

```
INSERT INTO Students
    VALUES (0, 'Peter Smith', '1938-11-11');
gi ERROR: duplicate key value violates unique constraint "students_pkey"
```

Slette ting

- For å slette ting (tabeller, skjemaer, brukere, osv.) fra databasen bruker vi DROP
- ◆ For å slette en tabell gjør vi DROP TABLE <tablename>;, f.eks.:

```
DROP TABLE Students;
```

- ◆ Tilsvarende for skjemaer, f.eks. DROP SCHEMA northwind;
- Av og til avhenger ting vi ønsker å slette på andre ting (f.eks. en tabell er avhengig av skjemaet den er i eller tabellene den refererer til)
- Vi kan ikke slette ting som andre ting avhenger av, uten å også slette disse
- For å slette en ting og alt som avhenger av den tingen kan vi bruke CASCADE
- Så for å slette northwind-skjemaet og alle tabeller som det inneholder kan vi gjøre

```
DROP SCHEMA northwind CASCADE;
```

Slette data

For å slette rader fra en tabell bruker vi DELETE:

```
DELETE
FROM <tabellnavn>
WHERE <betingelse>
```

◆ Så sletting av alle studenter født etter 1990-01-01 gjøres slik:

```
DELETE
FROM Students
WHERE StdBirthdate > '1990-01-01'
```

Oppdatere ting

- For å oppdatere skjemaelementer bruker vi ALTER
- Mens data oppdateres med UPDATE
- Vi kan f.eks. gjøre følgende:

```
ALTER TABLE Students RENAME TO UIOStudents;
```

for å omdøpe Students-tabellen til UIOStudents

Eller

```
ALTER TABLE Courses
ADD COLUMN Teacher text;
```

for å legge til en kolonne Teacher med type text til Courses-tabellen

• Alt i skjemaet kan endres med ALTER, se PostgreSQL-siden¹ for en oversikt

25 / 43

¹https://www.postgresql.org/docs/current/sql-altertable.html

Legge til skranker i ettertid

- Vi kan også legge til skranker etter at en tabell er laget
- ◆ Dette gjøres med kombinasjonen av ALTER TABLE og ADD CONSTRAINT
- For eksempel:

```
ALTER TABLE courses
ADD CONSTRAINT cid_pk PRIMARY KEY (cid);
```

29 / 43

Views

- Merk at vi nesten aldri er interessert i dataene slik de er lagret
- Vi må nesten alltid joine tabeller, filtrere vekk rader, projisere vekk kolonner, osv. for å få interessant data ut
- F.eks. i Filmdatabasen må man joine 3 tabeller for å finne ut hvilken skuespiller som spiller i hvilken film
- Hvorfor er det slik?
- Jo, fordi vi ønsker å representere dataene på slik måte at:
 - vi aldri repeterer data (gjør det enkelt å vedlikeholde, mer effektivt, osv.)
 - dataene kan brukes på mange forskjellige måter
- Vi bruker så spørringer for å få ut interessant data
- Av og til vil en bestemt spørring bli eksekvert veldig ofte
- Det er da upraktisk å måtte skrive den ut hver gang
- I slike tilfeller kan man lage et VIEW

Oppdatere data

◆ UPDATE lar oss oppdatere verdiene i en tabell:

```
UPDATE <tabellnavn>
    SET <oppdateringer>
WHERE <betingelse>
```

hvor <oppdateringer> er en liste med oppdateringer som blir eksekvert for hver rad som gjør <betingelse> sann

For eksempel:

```
UPDATE Students
   SET StdBirthdate = '1987-10-03'
WHERE StdName = 'Sam Penny'
```

oppdaterer fødselsdatoen til studenten Sam Penny til '1987-10-03'

Mens

```
UPDATE northwind.products
   SET price = price * 1.1
WHERE quantityperunit LIKE '%bottles%'
```

øker prisen med 10% på alle produkter som selges i flasker

30 / 43

Å lage views

Et view er egentlig bare en navngitt spørring, og lages slik:

```
CREATE VIEW StudentTakesCourse (StdName text, CourseName text)

AS

SELECT S.StdName, C.CourseName
FROM Students AS S,

Courses AS C,

TakesCourse AS T

WHERE S.SID = T.SID AND C.CID = T.CID
```

- Et view kan så brukes som om det var en vanlig tabell
- Men blir beregnet på nytt hver gang den brukes
- Så et view tar ikke opp noe plass og trengs ikke oppdateres
- Så,

```
SELECT *

SELECT S.StdName, C.CourseName

FROM StudentTakesCourse AS s

HERE s.StdName = 'Anna Consuma'

SELECT S.StdName, C.CourseName

FROM Students AS S, Courses AS C,

TakesCourse AS T

WHERE S.SID = T.SID AND

C.CID = T.CID) AS S

WHERE StdName = 'Anna Consuma'
```

Views som abstraksjoner

- Views kan også brukes for å bygge lag med abstraksjoner over tabellene
- F.eks. gitt følgende tabeller:


					akesco	urses
	students			sid	cid	semester
	sid	name	mail	1	1	h18
	1	Anna Consuma	anna@mail.no	1	2	v18
	2	Peter Young	py@uio.no	2	3	v18
	3	Mary Smith	smith@ifi.no	3	2	v19
				3	1	h19

courses				
cid	name	cred	lvl	
1	Databases	10	В	
2	Programming 101	5	В	
3	Advanced SQL	10	M	

33 / 43

Views for utledbare verdier

• I ER har vi utledbare attributter:




- Med views kan vi introdusere disse attributtene igjen
- Uten at vi trenger å lagre dem, holde dem oppdatert, osv.

person		
navn	fødselsdato	
Anna Consuma	1989-08-17	
Peter Young	1991-02-29	
Mary Smith	1993-01-01	

person_alder				
navn	fødselsdato	alder		
Anna Consuma	1989-08-17	30		
Peter Young	1991-02-29	28		
Mary Smith	1993-01-01	26		

Views som abstraksjoner



Materialiserte Views

- Dersom et view brukes veldig ofte kan det lønne seg å materialisere det
- Et materialisert view lagres som en vanlig tabell på disk
- De er derfor like effektive å kjøre spørringer mot som en vanlig tabell
- Lages slik:

- Men, den kan enkelt oppdateres når de tabellene den avhenger av oppdateres
- Dette skjer derimot ikke automatisk, man må kjøre følgende for å oppdatere det:

```
REFRESH MATERIALIZED VIEW person_alder;
```

SQL-scripts

- Når man lager en database vil man vanligvis lage et script som inneholder alle SQL-kommandoene som lager skjemaene, tabellene, viewsene, osv.
- Man kan så heller eksekvere dette scriptet, fremfor å kjøre hver spørring manuelt
- Følgende er et eksempel-script som lager Students-databasen

```
CREATE TABLE uio.students (sid SERIAL PRIMARY KEY, stdname text NOT NULL, stduiorthdate date);
CREATE TABLE uio.courses (cid SERIAL PRIMARY KEY, coursename text NOT NULL, credits int);
CREATE TABLE uio.takescourse (cid int REFERENCES uio.courses(cid),
                             sid int REFERENCES uio.students(sid), semester text);
CREATE VIEW studenttakescourse ( stdname text, coursename text )
AS SELECT s.stdname, s.coursename
   FROM uio.students AS s INNER JOIN uio.takescourse AS t ON (t.sid = t.sid)
        INNER JOIN uio.courses AS c ON (t.cid = c.cid);
INSERT INTO uio.students(stdname, stduiorthdate)
VALUES ('Anna Consuma', '1978-10-09'), ('Anna Consuma', '1978-10-09'),
       ('Peter Young', '2009-03-01'), ('Carla Smith', '1986-06-14');
INSERT INTO uio.courses(coursename, credits)
VALUES ('Data Management', 6), ('Finance', 10);
INSERT INTO uio.takescourse(sid, cid, semester)
VALUES (0,0,'A18'), (1,1,'S17'), (2,1,'S18'),
       (2,0,'S18'), (3,0,'A18');
```

Dump

- Et databasesystem kan også lage et script som gjenskaper dens database(r)
- I PostgreSQL gjøres dette med et eget program pg_dump på følgende måte:

```
pg_dump [flag] db > fil
```

hvor [flag] er de vanlige tilkobligsflaggene, db er navnet på databasen man vil dumpe, og fil er navnet på filen man vil skrive til.

- Andre databasesystemer har tilsvarende programmer
- Dette gjør det enkelt å duplisere eller dele databaser

37 / 43

SQL-scripts: Trygge kommandoer

- Dersom man forsøker å opprette en tabell som allerede finnes eller slette en tabell som ikke finnes så feiler kommandoen
- Dersom denne kommandoen er en del av en transaksjon, så feiler hele transaksjonen
- ◆ Dette kan hindres ved å bruke If EXISTS og IF NOT EXISTS i kommandoene
- For eksempel:

```
CREATE TABLE IF NOT EXISTS persons(name text, born date); -- Lager ny tabell
CREATE TABLE IF NOT EXISTS persons(name text, born date); -- Gir ingen error/lykkes
CREATE TABLE persons(name text, born date); -- Gir ERROR og feiler
DROP TABLE IF EXISTS persons; -- Sletter tabellen
DROP TABLE IF EXISTS persons; -- Gir ingen error/lykkes
DROP TABLE persons; -- Gir error, og feiler
```

- F.eks. nyttig dersom man oppdaterer scriptet som har generert en database
- Kan da kjøre scriptet for å kun få utført oppdateringene

SQL-scripts: Meta-kommandoer

- I et SQL-script har man også en del kommandoer som ikke er en del av SQL-språket
- F.eks. printe en beskjed, lage og gi verdier til variable, be om input fra en bruker, osv.
- Disse kommandoene har forskjellig syntaks fra RDBMS til RDBMS
- I PostgreSQL kan man printe en kommando ved å bruke \echo, f.eks.

```
\echo 'This is a message'
```

og brukes for å gi informasjon mens scriptet kjører (progresjon ol.)

 Dersom en konstant verdi brukes mye i et script kan man gi den et navn med \set, f.eks.

```
\set val 42
INSERT INTO meaning_of_life VALUES (:val);
```

- Merk kolonet foran navnet når verdien brukes
- Disse kan også brukes i psql direkte

Transaksjoner

- Når man oppdaterer databasen og noe går galt underveis øsnker man ofte at ingen av oppdateringene skal ha skjedd
- F.eks. kan man få delvis lagde tabeller, delvis insatt data, osv.
- For eksempel, se for dere f
 ølgende bank-overf
 øring:

```
UPDATE balances
SET balance = balance - 100
WHERE id = 1;

UPDATE balances
SET balance = balance + 100
WHERE id = 2;
```

- Dersom den f\u00farste oppdateringen feiler (f.eks. fordi balance < 100 men vi har en skranke balances >= 0) vil vi ikke at den andre skal utf\u00fares
- Det samme gjelder dersom vi får en feil mitt i et SQL-script
- Vi pakker derfor inn oppdateringer som skal utføres som en "enhet" i transaksjoner

Transaksjoner - Syntaks

Transaksjoner omsluttes av BEGIN og COMMIT slik:

```
BEGIN;

UPDATE balances
SET balance = balance - 100
WHERE id = 1;

UPDATE balances
SET balance = balance + 100
WHERE id = 2;

COMMIT;
```

42 / 43

ACID

For at transaksjoner skal fungere som forventet, tilfredstiller de fire kriterier:

- ◆ Atomicity Alle kommandoene i en transaksjon ansees som en enhet, og enten skal alle kommandoer lykkes, eller så skal alle kommandoer feile (feiler én så feiler alle)
- ◆ Concistency Dersom en transaksjon lykkes skal databasen ende opp i en konsistent tilstand (altså ingen skranker skal være brutt)
- Isolation Transaksjoner skal kunne kjøres i parallell, men resultatet skal da være likt som om transaksjonene ble kjørt sekvensielt
- Durability Etter at en transaksjon lykkes og har utført endringer på databasen, skal disse endringene alltid være utført (f.eks. dersom systemet restartes skal databasen fortsatt ha de samme endringene utført)

43 / 43